Hi

日本語LLM比較分析 2026

Rakuten AI 3.0 を含む主要LLMの法人向け活用ガイド

H A R M O N I C

i n s i g h t

2026年3月

アジェンダ

01 **日本語LLM市場の現状**
2026年のトレンドと主要プレイヤー

02 **グローバルLLM比較**
Claude / GPT / Gemini — 価格・性能・コンテキスト

03 **国産LLM比較**
Rakuten AI 3.0 / PLaMo / tsuzumi / ELYZA / 他

04 **総合比較マトリクス**
価格・性能・API可用性の一覧

05 **法人向け選定ガイド**
ユースケース別の推奨モデル

01

日本語LLM市場の現状

2026年のトレンドと主要プレイヤー

2026年 日本語LLM市場の全体像

グローバルLLMの日本語対応強化 × 国産LLMの台頭 = 選択肢の多様化

グローバルLLM（日本語対応強化）

- Claude 4.6 — 1Mトークン、文化的ニュアンス対応
- GPT-5.4 — 1.1Mコンテキスト、$2.50/1M入力
- Gemini 2.5 — 最安 $1.25/1M、マルチモーダル

国産LLM（ソブリンAI）

- Rakuten AI 3.0 — JP MT-Bench 8.88（最高）
- PLaMo 2.2 — 政府採用、API公開、¥300/1M
- tsuzumi 2 — 7B軽量、CPU動作可、オンプレ特化

2026年の注目トレンド

- データ主権（ソブリンAI）: 国産モデルへの政府・大企業需要が加速
- MoE アーキテクチャ: Rakuten AI 3.0 が 700B MoE で高効率を実証
- オンプレミス回帰: セキュリティ要件の厳しい金融・医療・官公庁でローカルLLM需要増
- コスト競争激化: Gemini Flash-Lite $0.10/1M 〜 Claude Opus $5.00/1M の幅広い選択肢

02

グローバルLLM比較

Claude / GPT / Gemini — 価格・性能・コンテキスト

グローバルLLM — 価格・性能比較

モデル	入力 $/1M tok	出力 $/1M tok	コンテキスト	特徴
Claude Opus 4.6	$5.00	$25.00	1M	最高精度・複雑推論・コード生成
Claude Sonnet 4.6	$3.00	$15.00	1M	Opus 98%性能・コスパ最良
Claude Haiku 4.5	$0.25	$1.25	200K	低コスト・高速応答
GPT-5.4	$2.50	$15.00	1.1M	最大コンテキスト・最新フラッグシップ
GPT-5 Mini	$0.25	—	—	バジェット向け
Gemini 2.5 Pro	$1.25	$10.00	1M	最安フロンティア・マルチモーダル
Gemini 2.5 Flash	$0.30	$2.50	1M	高速・低コスト・1Mコンテキスト

HARMONIC insight 製品は Claude API を標準採用 — BYOK で全モデル利用可能

* 価格は2026年3月時点。プロンプトキャッシュ・バッチAPIで最大90%削減可能（Claude）

グローバルLLM — 日本語ビジネス適性

Claude (Anthropic)

- 日本語文化的ニュアンス検知
- 1Mトークンコンテキスト
- コード生成 SWE-bench 80.8%
- プロンプトキャッシュ 90%OFF
- 40+言語多言語対応

GPT-5.4 (OpenAI)

- 1.1M最大コンテキスト
- 幅広いエコシステム
- GPT-4o比大幅性能向上
- 日本語MT-Bench未公開
- 長文 >272K は2倍課金

Gemini 2.5 (Google)

- 最安フロンティアモデル
- ネイティブマルチモーダル
- テキスト+画像+音声+動画
- コンテキストキャッシュ75%OFF
- Flash-Lite $0.10/1M（超低コスト）

法人向け推奨

- 高精度が必要な場合 → Claude Opus / Sonnet（文書校正・コード生成・複雑推論）
- コスト最優先の大量処理 → Gemini Flash / Flash-Lite（バッチ処理・要約）
- 既存OpenAI連携あり → GPT-5.4（エコシステム活用・既存投資保護）

03

国産LLM比較

Rakuten AI 3.0 / PLaMo / tsuzumi / ELYZA / その他

Rakuten AI 3.0 — 日本語MT-Bench最高スコア

基本スペック

- パラメータ: 700B (MoE) / 40B active
- アーキテクチャ: Mixture of Experts
- ベース: DeepSeek V3 アーキテクチャ
- ライセンス: Apache 2.0（オープンウェイト）
- 日本語MT-Bench: 8.88（GPT-4o 8.67超え）

API提供状況（重要）

- 公開API: なし（2026年3月時点）
- 利用方法: HuggingFaceからDL→セルフホスト
- 社内利用: Rakuten AI Gateway（内部のみ）
- HP提携: AI for Desktop（2026年春夏予定）
- 700B MoEのセルフホストは高コストGPU必要

日本語性能は最高だが、商用APIが存在しないため法人導入にはインフラ投資が必要

HARMONIC insight 製品への適用可否

- 現時点では不採用（APIなし・セルフホストのインフラコスト大）。HP Desktop版やAPI公開を注視。オンプレ要件のENT顧客向けに将来検討余地あり。

国産LLM — 主要モデル一覧

モデル	開発元	パラメータ	API	JP MT-Bench	特徴
Rakuten AI 3.0	楽天	700B MoE	なし	**8.88**	最高JP性能・Apache 2.0
PLaMo 2.2 Prime	PFN	31B	公開	7.85	政府採用・OpenAI互換API
Stockmark-2	Stockmark	100B	企業向け	7.48	ビジネス文書理解に強い
ELYZA-Shortcut	KDDI	32B	企業向け	GPT-4o級	KDDI基盤・医療特化あり
tsuzumi 2	NTT	7B / 0.6B	Azure MaaS	—	超軽量・CPU動作可・オンプレ
CALM3	CyberAgent	22.5B	OSS	—	Apache 2.0・完全日本語特化
Takane	富士通	—	企業向け	—	官公庁採用・1bit量子化・富岳

API欄 — 緑: 公開API / 茶: 企業向け限定 / 赤: 未提供

04

総合比較マトリクス

全モデルの価格・性能・API可用性を横断比較

総合比較マトリクス — コスト vs 性能

モデル	入力 $/1M	出力 $/1M	CTX	JP MT-B	API	OSS
Rakuten AI 3.0	セルフホスト	セルフホスト	—	**8.88**	x	o
Claude Sonnet 4.6	$3.00	$15.00	1M	—	o	x
Claude Haiku 4.5	$0.25	$1.25	200K	—	o	x
GPT-5.4	$2.50	$15.00	1.1M	—	o	x
Gemini 2.5 Pro	$1.25	$10.00	1M	—	o	x
Gemini 2.5 Flash-Lite	**$0.10**	**$0.40**	1M	—	o	x
PLaMo 2.2 Prime	~$2.00	~$6.70	32K	7.85	o	partial
tsuzumi 2 (7B)	企業向け	企業向け	—	—	限定	x

CTX = コンテキストウィンドウ / JP MT-B = 日本語MT-Bench / o = 利用可 / x = 不可

05

法人向け選定ガイド

ユースケース別の推奨モデル

ユースケース別 推奨モデル

高精度な日本語文書処理 契約書校正・議事録要約・顧客対応	**Claude Sonnet 4.6** 日本語文化ニュアンス対応、1Mコンテキスト、コスパ最良
大量バッチ処理・コスト最優先 FAQ生成・メール分類・データ抽出	**Gemini 2.5 Flash-Lite** $0.10/1M入力、1Mコンテキスト、超低コスト
データ主権・オンプレミス必須 金融・医療・官公庁（機密データ）	**tsuzumi 2 / PLaMo 2.2** GPU 1台で動作、完全国産、規制準拠
日本語最高精度（セルフホスト可） 大規模GPU環境ありの研究・大企業	**Rakuten AI 3.0** JP MT-Bench 8.88最高、Apache 2.0、700B MoE

HARMONIC insight: Claude BYOK 標準 + ローカルLLM対応（ENT）で柔軟な選択肢を提供

まとめ — Key Takeaways

1 **Rakuten AI 3.0 は日本語最高性能だが API 未提供**

JP MT-Bench 8.88 でGPT-4o超え。ただし商用APIなし。セルフホスト（700B MoE）にはGPUインフラ投資が必要。API公開を待つか、セルフホスト環境を構築するかの判断が必要。

2 **法人利用には Claude / GPT / Gemini が現実解**

API提供・SLA・サポート体制が整備済み。Claude Sonnet 4.6 がコスパ最良、Gemini Flash-Lite が最安。HARMONIC insight は Claude BYOK を標準採用。

3 **国産LLMは「ソブリンAI」需要で存在感**

PLaMo は政府採用・API公開で最もアクセスしやすい国産モデル。tsuzumi 2 は超軽量でオンプレ特化。データ主権要件の強い業界で需要増。

4 **モデル選定は「用途 x コスト x データ主権」で判断**

万能モデルはない。高精度、低コスト、オンプレの3軸でユースケースに最適なモデルを選択すべき。マルチLLM戦略が現実的。

HI

ありがとうございました

H A R M O N I C

i n s i g h t

h-insight.jp